

Detección de anomalías y predicción de rinde de soja y maíz mediante variables climáticas

1st Joaquín Castaños Zemborain
Universidad de San Andrés
Pehuajó, Argentina
jcastanoszemborain@udesa.edu.ar

2nd Baltasar Oostdijk Laumann
Universidad de San Andrés
Bahía Blanca, Argentina
boostdijklaumann@udesa.edu.ar

Resumen—En este trabajo abordamos dos problemas relacionados sobre el agro argentino: detectar campañas agrícolas con rinde anómalamente bajo (Componente A) y predecir el rinde de soja y maíz por departamento (Componente B). Para ello construimos un panel propio con datos públicos de rinde, clima, ENSO y satélite (307 departamentos de 15 provincias, campañas 1981/82–2024/25). En el Componente A comparamos baselines estadísticos y clásicos con autoencoders, y el mejor detector resultó un autoencoder variacional (VAE) con *score* probabilístico y promedio de 10 semillas: PR-AUC de 0,605 en soja y 0,515 en maíz sobre el test. En el Componente B comparamos regresión lineal regularizada, Random Forest, XGBoost, una red neuronal y un *stacking*, seleccionando hiperparámetros por validación cruzada temporal; el mejor modelo fue Random Forest en ambos cultivos (RMSE de test: 593 kg/ha y $R^2 = 0,40$ en soja; 1536 kg/ha y $R^2 = 0,41$ en maíz). Combinando ambos componentes estimamos la pérdida de la sequía 2022/23 en unos 15 millones de toneladas de soja y 20 de maíz.

Index Terms—predicción de rinde, detección de anomalías, autoencoder variacional, Random Forest, validación cruzada temporal

I. INTRODUCCIÓN

En Argentina el rinde agrícola depende fuertemente del clima de cada campaña: una sequía como la de 2022/23 puede reducir la producción nacional en decenas de millones de toneladas. Nos planteamos dos preguntas: (i) ¿podemos detectar, mirando solo el clima, qué campañas fueron anómalas para cada departamento?, y (ii) ¿podemos predecir cuántos kg/ha va a rendir cada departamento en una campaña dada?

La **entrada** de nuestros algoritmos es, para cada combinación de departamento, campaña y cultivo, un vector de 72 variables climáticas y satelitales de la ventana septiembre-marzo (temperaturas, lluvia, humedad, radiación, viento, índice ENSO, verdor NDVI, humedad de suelo y heladas). Con esa entrada, el **Componente A** usa un autoencoder variacional para producir un *score* continuo de anomalía (qué tan “raro” fue el clima y su efecto), y el **Componente B** usa modelos de regresión (el mejor: Random Forest [4]) para predecir el rinde en kg/ha. Ambos comparten el mismo panel de datos y el mismo corte temporal: entrenamos con el pasado (hasta 2020/21) y evaluamos con el futuro (2021/22–2024/25), como corresponde a un problema de pronóstico.

II. CONJUNTO DE DATOS

No usamos un dataset preexistente: lo construimos integrando fuentes públicas con un único script de ETL. Cada fila del

panel es una tupla *departamento* $\times$ *campaña* $\times$ *cultivo* (soja o maíz):

- **Target:** rinde en kg/ha de las Estimaciones Agrícolas del MAGyP [9], más superficie sembrada y producción, campañas 1981/82–2024/25 (la 2024/25 ya tiene rindes publicados y cae en el test).
- **Clima:** siete variables diarias de NASA POWER (`power.larc.nasa.gov`) en el centroide de cada departamento, promediadas por mes de septiembre a marzo (49 columnas).
- **ENSO:** índice ONI de NOAA, octubre–febrero (5 columnas).
- **Satélite:** NDVI AVHRR (verdor de la vegetación, 7 columnas), humedad de suelo y heladas de ERA5-Land (4 columnas) y lluvia satelital CHIRPS (7 columnas), todo procesado en Google Earth Engine sobre el polígono de cada departamento.

El panel crudo tiene 27 865 filas $\times$ 84 columnas; tras eliminar duplicados generados por departamentos homónimos de distintas provincias quedan **20 672 observaciones** (8 964 de soja y 11 708 de maíz), sobre 307 departamentos de 15 provincias y 43 campañas.

Partición. Es estrictamente temporal e igual en ambos componentes: train hasta 2020/21 (efectivo desde 1984/85, porque NASA POWER no tiene radiación en 1981–83) y test 2021/22–2024/25. No hay conjunto fijo de validación: los hiperparámetros se eligen con **validación cruzada temporal** (4 particiones expansivas sobre los años del train) y el test se usa una sola vez, al final. En el Componente B esto da 7 551 filas de train y 942 de test para soja, y 9 678 / 1 160 para maíz.

Preprocesamiento. El Componente A normaliza cada variable con un *z-score* *por departamento* (media y desvío calculados solo en el train), de modo que cada valor exprese qué tan inusual fue el clima *para ese lugar*. El Componente B estandariza las features (media 0, desvío 1, ajustado solo en train) y agrega tres derivadas: *year* (captura la tendencia tecnológica del rinde), *depto_enc* (el rinde promedio histórico del departamento, calculado sin mirar el test y con suavizado hacia la media global para departamentos con pocos datos) y cuatro variables agronómicas de la ventana crítica del cultivo (lluvia, estrés térmico, amplitud térmica y balance hídrico), llegando a 78 features.

III. COMPONENTE A: DETECCIÓN DE ANOMALÍAS

III-A. La etiqueta proxy z_rinde

Para poder evaluar al detector necesitamos saber qué campañas fueron realmente anómalas. Como no existe una etiqueta oficial, la construimos a partir de la historia de cada departamento: comparamos el rinde de cada campaña con la media y el desvío de las *cinco campañas anteriores* de ese mismo departamento, y marcamos como anómala toda campaña cuyo z -score sea menor que $-1,5$ (es decir, un rinde muy por debajo de lo esperable según su propia historia reciente). El cálculo usa solo campañas previas, nunca el año en curso. Históricamente resulta anómalo el 12,8 % de las campañas de soja y el 10,5 % de maíz; en el test la proporción sube a 26,6 % y 29,7 % por la sequía 2022/23. Importante: esta etiqueta se usa **solo para evaluar**. El detector se entrena sin etiquetas, aunque sobre un conjunto de entrenamiento “curado”: se excluyen las campañas marcadas por la etiqueta y los años de sequía generalizada (1988, 1996, 2008, 2017), para que aprenda cómo se ve una campaña normal. Por eso no es aprendizaje no supervisado “puro”, sino un esquema *one-class* con una curación débil del train.

III-B. Qué hicimos

La idea central es entrenar un modelo que reconstruya campañas normales: si una campaña nueva se reconstruye mal, es candidata a anomalía. Recorrimos una escalera de modelos, siempre con la misma evaluación (10 semillas, media y desvío):

1. **Baselines:** z -score multivariado promedio, distancia de Mahalanobis, Isolation Forest y One-Class SVM.
2. **Autoencoder (AE)** y **Denoising AE (DAE)**: redes que comprimen y reconstruyen la entrada, usando el error de reconstrucción (MSE) como score. Resultado: quedan *por debajo* de los baselines — sobre features ya normalizadas, el error plano no discrimina.
3. **VAE [1]**: la versión probabilística del autoencoder. Su ventaja no es la arquitectura sino el score: la *reconstruction probability* [2] pondera el error de cada variable por la incertidumbre que el modelo aprendió, y eso produce el salto de calidad (en soja, de $\sim 0,31$ del AE a $\sim 0,59$).
4. **Seed-ensemble**: como distintas semillas dan resultados distintos, el modelo final promedia el score de 10 VAEs con distinta inicialización. Esto estabiliza el resultado (el desvío entre corridas cae de $\pm 0,05$ a $\pm 0,01$) y mejora la media.

También incluimos Deep SVDD [3] (un método moderno de detección profunda), tuneado con el mismo presupuesto, como referencia. La configuración final del VAE: capas de 128 y 64 neuronas, espacio latente de dimensión 16, entrenado con Adam y *early stopping*.

III-C. Métricas y resultados

La métrica principal es **PR-AUC** (área bajo la curva precisión–recall): mide qué tan bien el ranking de scores concentra a las anomalías reales al principio; un detector

aleatorio obtiene la prevalencia (0,266 en soja, 0,297 en maíz). Reportamos también ROC-AUC. La Tabla I y la Fig. 1 resumen el test.

Cuadro I
COMPONENTE A: RESULTADOS EN TEST (PR-AUC / ROC-AUC).

Modelo	Soja		Maíz	
	PR	ROC	PR	ROC
z -score (promedio)	0.553	0.704	0.515	0.645
Mahalanobis	0.348	0.623	0.321	0.540
Isolation Forest	0.517	0.671	0.506	0.649
One-Class SVM (RBF)	0.485	0.695	0.436	0.610
AE (MSE)	0.312	0.548	0.319	0.536
DAE (MSE)	0.348	0.599	0.331	0.553
Deep SVDD (tuneado)	0.534	0.766	0.425	0.631
VAE (1 semilla)	0.588	0.741	0.488	0.630
VAE seed-ensemble $\times 10$	0.605	0.749	0.515	0.655




Figura 1. Componente A, soja: PR-AUC en test por modelo (media $\pm$ desvío entre semillas). El VAE con seed-ensemble es el mejor y el más estable.

En soja el VAE final supera con claridad a todos los demás. En maíz también queda primero, pero casi empatado con el z -score simple: buena parte de las anomalías de maíz no deja una firma climática visible (dependen de fechas de siembra, manejo, plagas), y ningún modelo que solo mire el clima puede detectarlas. La Fig. 2 lo ilustra: proyectando el espacio latente del VAE a 2D con t-SNE, un grupo de campañas anómalas (la sequía 2022/23) sí se separa del resto, y es exactamente el que recibe score alto; pero muchas otras anomalías quedan mezcladas entre las normales, y esas son indetectables para cualquier modelo que solo vea clima. Verificamos además la robustez del detector inyectando ruido en las features de test: la calidad se degrada de forma gradual, sin colapsos.

IV. COMPONENTE B: PREDICCIÓN DE RINDE

IV-A. Modelos

Comparamos una familia de modelos de complejidad creciente, todos implementados con scikit-learn [7], XGBoost [5] y PyTorch [8]:

- **Baselines:** la media global del train y la “climatología” (media histórica de cada departamento) — todo modelo útil debe superarlas.
- **Regresión lineal regularizada:** Ridge, Lasso y ElasticNet; la búsqueda eligió ElasticNet suave en soja y Ridge en maíz.




Figura 2. t-SNE del espacio latente del VAE en test (arriba: soja; abajo: maíz). Izquierda: color por etiqueta real (rojo = anómala). Derecha: color por score del VAE. El grupo anómalo de la sequía 2022/23 se separa y recibe score alto; el resto de las anomalías se mezcla con las normales: ese es el techo del problema.

- **Random Forest** [4]: promedio de 400 árboles de decisión (en soja con profundidad máxima 12 y mínimo 5 muestras por hoja; en maíz sin límite de profundidad), cada uno viendo la mitad de las features por división.
- **XGBoost** [5]: boosting de gradiente con árboles poco profundos y tasa de aprendizaje 0,02.
- **Red neuronal (MLP)**: dos capas ocultas (64 y 32), con *dropout*, *weight decay* y *early stopping*.
- **Stacking**: combina XGBoost y el MLP con una regresión Ridge entrenada sobre predicciones fuera-de-fold generadas de forma temporal.

Todos los hiperparámetros se eligieron con la validación cruzada temporal de 4 particiones descrita en la Sección II, recalculando `depto_enc` dentro de cada partición para no filtrar información del target (cuando detectamos y corregimos esa fuga, los errores de CV empeoraron ~ 30 kg/ha y hubo que re-tunear todo). Contra el sobreajuste usamos tres defensas: partición y CV siempre temporales (nunca aleatorias), modelos regularizados, y el test congelado hasta la evaluación final.

IV-B. Métricas y resultados

Reportamos **RMSE** (raíz del error cuadrático medio, en kg/ha, penaliza más los errores grandes; es nuestra métrica principal), **MAE** (error absoluto medio) y R^2 (fracción de la varianza explicada). La Tabla II muestra el test y la Fig. 3 el predicho contra el real del mejor modelo.

El mejor modelo fue Random Forest en ambos cultivos, y según el test estadístico de Diebold–Mariano [6] su ventaja sobre cada competidor es significativa ($p < 0,01$). En soja, RF también había ganado la validación cruzada; en maíz la CV daba un empate técnico entre los métodos de árboles, pero en test RF se despegaba con claridad. Tiene sentido que ganen los

Cuadro II
COMPONENTE B: RESULTADOS EN TEST (RMSE Y MAE EN KG/HA).

Modelo	Soja			Maíz		
	RMSE	MAE	R^2	RMSE	MAE	R^2
Media global	776	652	-0.03	2166	1762	-0.17
Climatología (depto)	708	593	0.15	1785	1501	0.21
Lineal regularizado	661	508	0.26	1970	1520	0.04
Red neuronal (MLP)	665	520	0.25	2019	1596	-0.01
Stacking	649	508	0.28	1956	1500	0.05
XGBoost	606	470	0.37	1721	1304	0.27
Random Forest	593	465	0.40	1536	1144	0.41




Figura 3. Rinde predicho vs. real en test para Random Forest (izquierda: soja; derecha: maíz). El modelo subestima los extremos, y los puntos con rinde real ≈ 0 (lotes abandonados) son el principal caso de falla.

árboles: capturan umbrales e interacciones no lineales típicas del agro (por ejemplo, “si llueve menos de cierto nivel en la ventana crítica, el rinde se derrumba”), mientras que el modelo lineal promedia regiones con relaciones clima–rinde distintas (en maíz queda incluso por debajo de la climatología) y la red neuronal no compensa su mayor varianza con estos tamaños de datos. Las features más importantes resultaron `depto_enc` y `year` (dónde y cuándo), seguidas por el NDVI de enero–febrero y el balance hídrico de la ventana crítica. El gap entre CV y test es moderado (en soja, 615 vs. 593 de RMSE), señal de que no sobreajustamos la selección.

IV-C. Uso conjunto de los dos componentes

Los componentes se complementan en dos sentidos. Primero, agregar el espacio latente del VAE como features del regresor reduce el RMSE de test entre un 3 % (soja) y un 7 % (maíz): el detector aporta un resumen del contexto climático que el regresor aprovecha. Segundo, el predictor le pone números a las anomalías del detector: para cada departamento anómalo de 2022/23 predecimos el rinde que *hubiera* tenido con un clima normal (reemplazando las variables climáticas del año por su mediana histórica) y multiplicamos la brecha por la superficie sembrada. El resultado (Fig. 4) estima la pérdida de la sequía en $\sim 14,7$ millones de toneladas de soja y $\sim 20,0$ de maíz, un orden de magnitud compatible con las estimaciones públicas de la Bolsa de Comercio de Rosario [10].




Figura 4. Pérdida estimada por departamento en la sequía 2022/23 (rinde contrafactual — real, por superficie sembrada). Izquierda: soja; derecha: maíz.

V. CONCLUSIÓN Y TRABAJO FUTURO

Construimos un panel público y reproducible de 20 672 observaciones y, sobre él, evaluamos dos componentes acoplados bajo un protocolo temporal estricto. En detección de anomalías, el VAE con score probabilístico y promedio de semillas fue el mejor modelo en ambos cultivos (PR-AUC 0,605 en soja y 0,515 en maíz), aunque con una brecha marcada entre ellos: en soja tanto el VAE single como el ensemble superaron a todos los baselines, mientras que en maíz el single mostró alta variabilidad y solo el ensemble logró superarlos por poco. El salto de calidad provino del score y del ensemble, no de agrandar la red. En predicción de rinde, Random Forest ganó en ambos cultivos (RMSE 593 y 1536 kg/ha; $R^2 \approx 0,4$) con diferencias estadísticamente significativas, confirmando que sobre datos tabulares de tamaño medio los ensembles de árboles siguen siendo lo más efectivo. La integración de ambos componentes permitió además cuantificar la sequía 2022/23 con resultados compatibles con estimaciones externas.

El hallazgo central, sin embargo, es más matizado. Tanto el t-SNE del espacio latente como el histograma de scores (Figs. 2 y ??) muestran el mismo patrón: el modelo aísla con claridad un subconjunto chico y extremo de anomalías —un cluster casi puro por un lado, una cola larga de scores altos por el otro—, pero para el grueso de los casos anómalos no aparece una frontera limpia, ni geométrica ni de score, que los separe de las campañas normales. Interpretamos esto como evidencia de que las anomalías de rinde no se explican en su totalidad por la firma climática que atraviesa el ciclo del cultivo: factores como plagas, estado del suelo u otras variables hoy ausentes del dataset probablemente den cuenta de la porción que el modelo no logra capturar. Esto es coherente con la mayor dificultad observada en maíz, cuyo rinde parece menos ligado a las variables climáticas disponibles que el de soja. En esa dirección, sumar nuevas fuentes de datos —imágenes satelitales de mayor resolución durante la campaña, indicadores de suelo y de sanidad del cultivo—, junto con modelos jerárquicos por zona, intervalos de predicción y un tratamiento explícito de los lotes abandonados (rinde ≈ 0 , hoy nuestro principal caso de falla), constituye una línea de investigación con potencial de mejora concreta.

REFERENCIAS

[1] D. P. Kingma and M. Welling, “Auto-encoding variational Bayes,” in *Proc. ICLR*, 2014, arXiv:1312.6114.

[2] J. An and S. Cho, “Variational autoencoder based anomaly detection using reconstruction probability,” SNU Data Mining Center, Tech. Rep., 2015.

[3] L. Ruff *et al.*, “Deep one-class classification,” in *Proc. ICML*, 2018, pp. 4393–4402.

[4] L. Breiman, “Random forests,” *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.

[5] T. Chen and C. Guestrin, “XGBoost: A scalable tree boosting system,” in *Proc. ACM SIGKDD*, 2016, pp. 785–794.

[6] F. X. Diebold and R. S. Mariano, “Comparing predictive accuracy,” *J. Business & Economic Statistics*, vol. 13, no. 3, pp. 253–263, 1995.

[7] F. Pedregosa *et al.*, “Scikit-learn: Machine learning in Python,” *J. Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.

[8] A. Paszke *et al.*, “PyTorch: An imperative style, high-performance deep learning library,” in *Proc. NeurIPS*, 2019.

[9] Ministerio de Agricultura, Ganadería y Pesca (Argentina), “Estimaciones agrícolas,” datos.magyp.gob.ar, 2025.

[10] Bolsa de Comercio de Rosario, “El costo de la sequía 2022/23,” Informe técnico, 2023.