

Enunciado de Proyecto Final

Sistema Integrado de Pronóstico y Detección de Anomalías en Campañas Agrícolas

Acoplamiento de un modelo supervisado de rinde con un detector no supervisado para soja y maíz en la región núcleo argentina

Motivación

El sector agropecuario argentino enfrenta dos problemas que se suelen abordar por separado, pero que en la práctica están profundamente acoplados: **(i) pronosticar el rinde esperado** de cada departamento campaña a campaña, y **(ii) detectar campañas anómalas** en las que factores climáticos extremos producen pérdidas significativas. La sequía 2022/23 ilustra el acoplamiento: un modelo predictivo que ignora las anomalías falla exactamente cuando más se lo necesita, y un detector de anomalías sin un baseline de rinde esperado no puede cuantificar la magnitud de la pérdida.

Este proyecto propone un **sistema integrado** que combina ambos componentes y los hace validarse mutuamente: el detector aporta features de contexto climático al predictor, y el predictor permite cuantificar económicamente las anomalías detectadas.

Conjunto de Datos

Se construirá un panel **departamento × campaña × cultivo** integrando cuatro fuentes públicas, todas con cobertura argentina:

- **Estimaciones Agrícolas (MAGyP)**, datos.magyp.gob.ar/dataset/estimaciones-agricolas — rendimiento (kg/ha), superficie sembrada y cosechada por campaña × cultivo × departamento. Soja y maíz desde 1969.
- **NASA POWER** (comunidad AG), power.larc.nasa.gov — clima diario por centroide departamental desde 1981: T2M, T2M_MAX/MIN, PRECTOTCORR, RH2M, ALLSKY_SFC_SW_DWN, WS2M.
- **NDVI subnacional Argentina** (HDX-WFP, dataset arg-ndvi-subnational) — NDVI dekadal MODIS C6.1 agregado por unidad administrativa.
- **Oceanic Niño Index (ONI)** de NOAA — índice ENSO mensual, dominio público.

Cobertura geográfica principal: región núcleo (centro-sur de Santa Fe, sudeste de Córdoba, norte de Buenos Aires), con extensión opcional a Entre Ríos y La Pampa. El panel resultante tendrá aproximadamente **50 campañas × 50 departamentos × 2 cultivos** (soja y maíz). El ETL será desarrollado una sola vez y compartido por ambos componentes del sistema.

Tarea fundamental

Desarrollar un sistema integrado de dos componentes acoplados:

Componente A — Detección de anomalías (no supervisado)

Aprender, mediante un autoencoder multivariado, la representación de una campaña “normal” por departamento y devolver para cada campaña: (i) un **score de anomalía** continuo basado en el error de reconstrucción, (ii) una clasificación binaria normal/anómala con un umbral calibrado, y (iii) un **embedding latente** que sirva de feature para el componente B.

Componente B — Pronóstico de rinde (supervisado)

Predecir el rinde (kg/ha) por departamento × campaña × cultivo en dos momentos del calendario agrícola: **pre-siembra** (solo features estructurales y ONI) y **pre-cosecha** (incorporando clima y NDVI observados hasta enero/febrero). El predictor utilizará como features adicionales el score y embedding del componente A.

Integración (núcleo del proyecto)

Los dos componentes se acoplan en tres puntos explícitos:

- **Detector → Predictor:** el score de anomalía y el embedding latente del autoencoder se incorporan como features del modelo de rinde. Esperamos que el predictor mejore especialmente en campañas extremas, ya que el AE provee contexto climático comprimido.
- **Predictor → Detector:** una vez entrenado el predictor, las anomalías detectadas se **cuantifican económicamente** mediante la diferencia entre rinde esperado contrafactual (predicho bajo condiciones normales) y rinde real, ponderada por superficie sembrada.
- **Validación cruzada entre componentes:** una campaña genuinamente anómala debería ser simultáneamente (i) detectada por el AE como alto error de reconstrucción y (ii) presentar residuo alto en el predictor. La consistencia entre ambas señales es un test de robustez metodológica.

El trabajo deberá incluir:

1. Definición formal de las tareas de detección y pronóstico.
2. Diseño y justificación del split temporal y de los subconjuntos de campañas “normales”.
3. Implementación y evaluación de distintos modelos para ambos componentes.
4. Análisis explícito de la integración: aporte del detector al predictor, y del predictor a la cuantificación de anomalías.

Diseño de splits

Se utilizará un **split temporal estricto** por campaña, compartido entre ambos componentes:

- **Train:** campañas 1981/82 a 2017/18.
- **Validación:** campañas 2018/19 a 2020/21.
- **Test:** campañas 2021/22 a 2023/24 (incluye explícitamente 2022/23 como caso anómalo).

Para el componente A (detector), el autoencoder se entrenará **exclusivamente sobre campañas normales** dentro del periodo de train (excluyendo 2008/09, 2017/18 y otros años Niña fuerte), de modo que aprenda a reconstruir el patrón típico y falle sobre los extremos. Para el componente B (predictor) se utilizará walk-forward CV re-entrenando para cada año de test. **No** se hará random split de filas en ningún caso, porque produciría leakage temporal (features de campañas posteriores informando predicciones de campañas anteriores).

La estrategia de división se justificará considerando:

- Variables espurias: cambios tecnológicos (variedades, fertilización), tendencia secular del rinde, cambios en metodología de medición.
- Escenario de uso: el sistema se utiliza ex ante para anticipar campañas futuras, no retrospectivamente.
- Riesgos de leakage: features que filtren información del futuro, normalización mal computada (usar estadísticas globales en vez de solo de train), filtrado de anomalías con criterios que dependan del test set.

Features

Se deberán explorar, como mínimo, dos representaciones distintas, compartidas entre ambos componentes:

- **Features expertas agronómicas** por campaña × departamento: lluvia acumulada por fase fenológica (siembra, vegetativo, R1–R5 / VT–R1, llenado de grano), grados-día acumulados (GDD), días con $T > 35^{\circ}\text{C}$, déficit hídrico estimado, anomalía NDVI integral, ONI promedio Oct–Mar, lags del rinde (1 a 5 años), media móvil del rinde, indicadores categóricos Niña/Niño/Neutro.
- **Representación tabular extendida**: promedios mensuales Sep–Mar de cada variable climática y NDVI dekadal. Esta es la representación de input principal para el autoencoder.

La normalización deberá realizarse **por departamento** (z-score por unidad) para no confundir variabilidad climática regional estructural con anomalía de campaña, y los parámetros de normalización (media y desvío) deberán computarse exclusivamente sobre el conjunto de train.

Para el componente B, además, se incorporarán como features: (i) el score de anomalía del componente A y (ii) la representación latente del autoencoder. El aporte marginal de estas features se medirá explícitamente como ablation.

Modelos

Componente A — Detector de anomalías

- **Baselines**: z-score multivariado, distancia de Mahalanobis e Isolation Forest sobre las features expertas.
- **Modelo principal**: autoencoder denso entrenado con MSE sobre años normales. El error de reconstrucción funciona como score de anomalía.

- **Extensión:** autoencoder variacional (VAE) para obtener un espacio latente continuo, visualizable con PCA o t-SNE.

Componente B — Predictor de rinde

- **Baseline 1:** media histórica del rinde por departamento (climatología).
- **Baseline 2:** regresión lineal con regularización Ridge / Lasso.
- **Ensembles:** Random Forest y XGBoost, con tuning por CV temporal.
- **Modelo profundo:** MLP feed-forward con regularización L2 y dropout.
- **Modelo integrado:** cualquiera de los anteriores aumentado con score + embedding del componente A.

Stacking opcional como extensión, combinando XGBoost y MLP. Hiperparámetros a ajustar y justificar: dimensión del cuello de botella del AE, λ de regularización, profundidad y número de árboles en RF, learning rate y profundidad en XGBoost, arquitectura, dropout y regularización en el MLP.

Evaluación y Análisis

Métricas del Componente A

Ground truth proxy objetivo: Z-rinde respecto del promedio móvil de 5 años con umbral $Z < -1,5$ y/o $ONI \leq -0,5$ sostenido Oct–Feb. Métricas: ROC-AUC, PR-AUC y F1 de la clase anómala. Análisis cualitativo del ranking de anomalías detectadas vs. eventos documentados por BCR e INTA.

Métricas del Componente B

Métrica principal: RMSE en kg/ha. Complementarias: MAE, SMAPE, R^2 y skill score vs. climatología. Test de Diebold–Mariano para comparar significativamente los modelos.

Métricas de integración (el aporte distintivo del proyecto)

- **Lift del detector sobre el predictor:** diferencia de RMSE del predictor con vs. sin features del autoencoder, descompuesta entre campañas normales y anómalas. La hipótesis es que el lift se concentra en las anómalas.
- **Consistencia cruzada:** correlación de Spearman entre el score de anomalía del AE y el valor absoluto del residuo del predictor, calculada sobre el test set. Alta correlación es indicador de que ambos componentes detectan la misma estructura.
- **Cuantificación económica de anomalías:** para cada anomalía detectada, computar pérdida estimada como $(\text{rinde contrafactual predicho} - \text{rinde real}) \times \text{superficie sembrada}$, comparando el agregado contra estimaciones publicadas (BCR reportó USD 14.140 M de pérdida en 2022/23).
- **Análisis contrafactual de 2022/23:** predecir qué hubiera rendido cada departamento bajo condiciones climáticas “normales” y discutir la heterogeneidad espacial de la pérdida.

Ablations

- Componente A: con/sin NDVI, con/sin ONI, autoencoder denso vs. variacional, dimensión del cuello de botella.
- Componente B: aporte marginal de NDVI, ONI y lags del rinde; modelo separado por cultivo vs. conjunto.
- Integración: predictor sin features del AE, con score únicamente, con score + embedding.

Referencias de Estado del Arte

1. Sakurada, M., & Yairi, T. (2014). Anomaly Detection Using Autoencoders with Nonlinear Dimensionality Reduction. MLSDA Workshop.
2. An, J., & Cho, S. (2015). Variational Autoencoder based Anomaly Detection using Reconstruction Probability. SNU Tech Report.
3. Schwalbert, R. et al. (2020). Forecasting maize yield at field scale based on high-resolution satellite-derived vegetation indices. Field Crops Research.
4. Cao, J. et al. (2021). Integrating multi-source data for rice yield prediction across China using machine learning and deep learning approaches. Agricultural and Forest Meteorology.
5. Bolsa de Comercio de Rosario (2023). El costo de la sequía 2022/23. (Contextualización del caso de estudio y benchmark externo de pérdida económica.)
6. INTA — Trabajos publicados sobre rendimiento y ENSO en la pampa argentina.

Ideas para extensiones

1. **Tipología de anomalías:** clustering del espacio latente del autoencoder (DBSCAN o GMM) para distinguir sequía vs. exceso hídrico vs. helada tardía.
2. **Detección y pronóstico a media campaña:** usar features hasta enero para anticipar la anomalía y actualizar el rinde esperado antes de cosecha.
3. **Intervalos de predicción:** quantile regression con XGBoost o quantile loss en el MLP, para reportar el rinde como banda de incertidumbre.
4. **Benchmark externo:** comparar las predicciones del modelo contra los pronósticos públicos de GEA-BCR y PAS-BCBA, evaluando si el sistema integrado los iguala o los supera.
5. **Extensión geográfica:** aplicar el pipeline completo a otras regiones agroecológicas (NOA, NEA) y evaluar la transferencia entre regiones.