

Proyecto Final

Bautista Garcia
Universidad de San Andrés
garciab@udesa.edu.ar

Tomas Gonzalez
Universidad de San Andrés
tgonzalez@udesa.edu.ar

Resumen—El reconocimiento de emociones en el habla (SER) busca detectar el estado afectivo de una persona a partir de su voz, con aplicaciones que van de la atención al cliente a la salud. En este trabajo armamos un sistema de SER sobre RAVDESS comparando dos familias de representaciones (las features expertas eGeMAPS y los embeddings auto-supervisados de wav2vec 2.0, WavLM y HuBERT) y una escalera de modelos de complejidad creciente: Random Forest, regresión logística, redes densas y recurrentes, y *fine-tuning* end-to-end. Con validación cruzada estricta por hablante (GroupKFold-5), un ensemble ponderado de clasificadores lineales sobre varios backbones SSL más una red densa entrenada con aumentación de pseudo-hablantes llega a 0,890 de accuracy (0,888 de macro-F1), partiendo de un baseline de 0,465. La normalización por hablante (CMVN) resultó la mejora individual más grande (+7 puntos), y los modelos de mayor capacidad no superaron al enfoque lineal con los datos disponibles. Evaluado sin reentrenar sobre EMODB (en alemán), el sistema conserva 0,767 de accuracy sobre las seis clases compartidas, y de nuevo es CMVN lo que explica la mayor parte de la recuperación frente al cambio de dominio.

Index Terms—reconocimiento de emociones en el habla, aprendizaje auto-supervisado, ensembles, normalización por hablante, cambio de dominio

I. INTRODUCCIÓN

Detectar la emoción de una persona a partir de su voz tiene aplicaciones bien concretas. En un centro de atención al cliente, por ejemplo, serviría para monitorear cómo evoluciona el ánimo de los agentes a lo largo de sus llamadas y detectar desgaste a tiempo, sin agregar nada a la infraestructura que ya existe, porque las llamadas ya se graban. El desafío técnico es que la señal de voz mezcla qué se dice, quién lo dice y cómo se dice. La emoción vive en el tercer componente, pero los dos primeros, sobre todo la identidad del hablante, dominan la señal acústica. Un sistema entrenado sin cuidado aprende a reconocer voces en lugar de emociones, y falla justo en el escenario de uso real: hablantes que nunca vio.

La entrada de nuestro algoritmo es una señal de audio de voz (mono, a 16 kHz, de duración variable). A partir de ella extraemos una representación de dimensión fija y usamos clasificadores supervisados para predecir una de ocho emociones (neutral, calma, felicidad, tristeza, enojo, miedo, disgusto y sorpresa). Encaramos el trabajo con dos preguntas. Primero, ¿qué representación captura mejor la emoción, las features acústicas expertas o las aprendidas por modelos auto-supervisados (SSL)? Segundo, ¿cuánta capacidad de modelo aguanta un dataset de ~1400 ejemplos? Como extensión, evaluamos el sistema final sin reentrenarlo sobre un corpus

en otro idioma (EMODB, en alemán) para medir el efecto del cambio de dominio.

II. CONJUNTO DE DATOS Y CARACTERÍSTICAS

II-A. RAVDESS

Trabajamos con RAVDESS [1]: 24 actores profesionales (12 mujeres y 12 hombres) que dicen dos frases léxicamente idénticas con acento norteamericano neutro. El canal de habla tiene 1440 audios (8 emociones $\times$ 2 frases $\times$ 2 repeticiones $\times$ 2 intensidades $\times$ 24 actores, con la excepción de la clase neutral, que solo existe en intensidad normal y por eso tiene la mitad de ejemplares). El corpus trae además un canal cantado (1012 audios) que usamos solo en la exploración inicial. Todos los resultados que reportamos son sobre el canal de habla. El desbalance de neutral motiva usar macro-F1 como métrica complementaria y pesos por clase al entrenar.

II-B. Variables espurias y diseño de splits

El análisis exploratorio mostró que la variación entre hablantes (y entre géneros) en las features prosódicas es comparable o mayor que la variación entre emociones. La identidad es un *confound* directo para la tarea. Como cada actor aporta 60 audios, un split aleatorio por muestra filtraría voces del test al entrenamiento y sobreestimaría el rendimiento. Por eso evaluamos con GroupKFold de 5 particiones agrupando por actor: ningún hablante aparece a la vez en entrenamiento y evaluación.

Un punto que queremos dejar claro: no apartamos un conjunto de test propio de RAVDESS. Con 24 hablantes, reservar actores para un test separado nos dejaba muy pocos para entrenar, así que todas las métricas que reportamos son de *validación*, calculadas sobre las predicciones out-of-fold de la validación cruzada. La evaluación sobre EMODB, que el modelo no ve en ningún momento del desarrollo, es nuestro único test realmente externo. La intensidad y el texto, balanceados por diseño en RAVDESS, no necesitaron control extra.

II-C. Representaciones

Exploramos las dos familias requeridas. **eGeMAPS** [2]: 88 funcionales acústicos por audio (estadísticos de F0, energía, formantes y espectro) extraídos con openSMILE [3]. Es el conjunto experto estándar en SER. **Embeddings SSL**: las representaciones internas de wav2vec 2.0 base [4] (95M de parámetros, 12 capas transformer de dimensión 768), WavLM-large [5] y HuBERT-large [6] (ambos de 317M, con 24

capas de dimensión 1024), pre-entrenados sobre miles de horas de habla sin etiquetas. Siguiendo a Pepino et al. [7], tratamos la capa de la que se extrae el embedding como un hiperparámetro a investigar en vez de quedarnos con la última. Como preprocesamiento, todo audio se convierte a mono 16 kHz. Para EMOBDB aplicamos exactamente el mismo pipeline, sin ninguna adaptación.

II-D. EMOBDB para evaluación cross-corpus

EMODB [9] tiene 535 audios de 10 actores en alemán con 7 emociones. Seis coinciden con RAVDESS (neutral, felicidad, tristeza, enojo, miedo y disgusto). Descartamos *aburrimiento*, que no tiene equivalente, y evaluamos sobre los 454 audios restantes sin reentrenar ni recalibrar el modelo.

III. METODOLOGÍA

III-A. De la señal al vector de features

Un forward por el modelo SSL produce estados ocultos $\mathbf{h}_t^{(\ell)} \in \mathbb{R}^H$ para cada capa ℓ y frame t (unos 50 frames por segundo). La representación de un audio en la capa ℓ es el promedio temporal (*mean pooling*):

$$\mathbf{x}^{(\ell)} = \frac{1}{T} \sum_{t=1}^T \mathbf{h}_t^{(\ell)}, \quad (1)$$

y la representación multi-capas concatena las tres mejores capas del barrido: $\mathbf{x} = [\mathbf{x}^{(\ell_1)}; \mathbf{x}^{(\ell_2)}; \mathbf{x}^{(\ell_3)}]$.

III-B. Normalización por hablante (CMVN)

Para sacarle a las features la identidad del hablante aplicamos *cepstral mean and variance normalization* por hablante. Si $\boldsymbol{\mu}_s$ y $\boldsymbol{\sigma}_s$ son la media y el desvío de las features del hablante s ,

$$\tilde{\mathbf{x}} = (\mathbf{x} - \boldsymbol{\mu}_s) \oslash \boldsymbol{\sigma}_s, \quad (2)$$

con $\oslash$ la división elemento a elemento. Cada audio queda representado como su desviación respecto del punto neutro de su propio hablante, que es justo donde vive la emoción. Las estadísticas se calculan por hablante dentro de cada conjunto, sin cruzar información entre folds.

III-C. Modelos

Probamos una escalera de modelos de complejidad creciente. Los hiperparámetros salieron de la misma validación cruzada.

Random Forest (el baseline requerido): 300 a 400 árboles con pesos de clase balanceados.

Regresión logística: como acá $d \gg n$ (hasta 3072 features para 1440 audios) usamos regularización fuerte con $C=0,01$ ($C=0,1$ en la comparación inicial, de dimensión menor), estandarización previa y pesos de clase balanceados.

MLP: dos capas ocultas (512 y 256) con ReLU, batch-norm de entrada, dropout de 0,3, Adam ($\eta=10^{-3}$, weight decay 10^{-4}), batch de 64 y *early stopping* con paciencia 10 sobre una validación interna estratificada del 15 % del fold de entrenamiento.

CRNN: para aprovechar la dinámica temporal que el mean pooling descarta, un modelo secuencial que trabaja sobre los frames sin promediar: Conv1D (256 canales, kernel 5), después una BiGRU (128) y al final *attention pooling*, donde el peso de cada frame se aprende como $\alpha_t = \text{softmax}_t(\mathbf{w}^\top \mathbf{o}_t)$ y el contexto es $\mathbf{c} = \sum_t \alpha_t \mathbf{o}_t$. Cumple el requisito de combinar capas convolucionales, recurrentes y densas.

Fine-tuning end-to-end: ajuste del backbone SSL completo con una cabeza de clasificación, lr de $2 \cdot 10^{-5}$ con warmup del 10 % (lo estándar para transformers pre-entrenados), encoder convolucional congelado, batch de 4 a 8 y early stopping.

III-D. Aumentación de pseudo-hablantes

Con 24 hablantes nomás, generamos variantes de cada audio que suenan como otra persona: perturbación de velocidad (factores 0,9 y 1,1, que también corren el pitch) y ruido gaussiano (SNR 20 dB). Los embeddings de las variantes heredan la etiqueta del original y se suman únicamente al entrenamiento, y solo si su hablante de origen pertenece al fold de train. Si no, la misma voz (deformada) aparecería de los dos lados del split.

III-E. Ensemble

El modelo final combina K clasificadores por votación blanda ponderada:

$$P(y | a) = \frac{1}{\sum_k w_k} \sum_{k=1}^K w_k P_k(y | a), \quad (3)$$

con cuatro votantes: regresiones logísticas sobre WavLM-large (top-3 capas, $w=2$), HuBERT-large ($w=2$) y wav2vec2-base ($w=1$), más el MLP con aumentación sobre WavLM+base concatenados ($w=1$). Todos los votantes trabajan sobre features con CMVN. Los pesos los elegimos por validación cruzada entre variantes discretas.

III-F. Protocolo de evaluación

La métrica principal es accuracy y la complementaria macro-F1, $F1_{\text{macro}} = \frac{1}{C} \sum_c F1_c$, que promedia sin ponderar por soporte y por eso castiga ignorar a la clase minoritaria (neutral). Las dos se calculan sobre las predicciones out-of-fold del GroupKFold-5 por actor. Como dijimos en la Sección II-B, son métricas de validación: no hay un test set separado de RAVDESS. Para EMOBDB el modelo final se entrena sobre todo RAVDESS speech y se evalúa sin reentrenamiento.

IV. EXPERIMENTOS Y RESULTADOS

IV-A. Features expertas vs. aprendidas

La Tabla I compara los dos modelos base sobre las tres representaciones iniciales. Se ven dos cosas: los embeddings SSL superan por mucho a eGeMAPS con los dos clasificadores, y la regresión logística, con la regularización adecuada, le gana al Random Forest en el espacio de alta dimensión. Combinar eGeMAPS con wav2vec aporta poco ya desde esta etapa, primera señal de una redundancia que después se confirma.

Tabla I
MODELOS BASE $\times$ REPRESENTACIÓN (SPEECH, GROUPKFOLD-5).

Modelo	Representación	Accuracy	Macro-F1
Random Forest	eGeMAPS (88)	0,465	0,449
Random Forest	wav2vec capa 8 (768)	0,588	0,576
Random Forest	combinado (856)	0,597	0,582
LogReg	eGeMAPS (88)	0,518	0,511
LogReg	wav2vec capa 8 (768)	0,721	0,715
LogReg	combinado (856)	0,727	0,721




Figura 1. Rendimiento por capa. Arriba: wav2vec2-base (evaluado con RF, sin CMVN). Abajo: WavLM-large (LogReg + CMVN). En los dos casos las capas intermedias superan a las finales.

IV-B. ¿Qué capa del modelo SSL?

La Figura 1 muestra el barrido por capa para los dos backbones. El patrón se repite: el rendimiento sube hasta las capas intermedias y cae hacia las últimas, que están especializadas en el objetivo de pre-entrenamiento (predecir unidades enmascaradas) y descartan información prosódica. Nos quedamos con las tres mejores capas de cada backbone (8-6-7 en wav2vec2-base, 13-11-10 en WavLM-large y 13-14-12 en HuBERT-large) y las concatenamos.

IV-C. El efecto de normalizar por hablante

La Tabla II aísla las dos mejoras de representación. CMVN por hablante es la mejora individual más grande de todo el trabajo: +7 puntos de accuracy sin tocar el modelo (0,732 $\rightarrow$ 0,803), lo que confirma que buena parte del error venía del confound de identidad. La concatenación multi-capas suma unos 2 puntos más y eGeMAPS apenas medio punto: la información experta ya está casi toda contenida en los embeddings.

Tabla II
EFECTO DE CMVN Y MULTI-CAPA (LOGREG $C=0,01$, WAV2VEC2-BASE).

Representación	Accuracy	Macro-F1
capa 8	0,732	0,727
capa 8 + CMVN	0,803	0,797
top-3 capas	0,736	0,731
top-3 + CMVN	0,822	0,815
top-3 + eGeMAPS + CMVN	0,827	0,821




Figura 2. Recorrido de optimización: del baseline al ensemble final.

IV-D. Redes neuronales: la capacidad no alcanza

Acá vino la primera sorpresa. Sobre la misma representación, el MLP quedó por debajo del modelo lineal (0,796 contra 0,827) y el CRNN sobre secuencias frame-level, aun con acceso a la dinámica temporal completa, quedó más abajo todavía (0,763). Con 1440 ejemplos la capacidad extra se convierte en varianza: los dos modelos sobreajustan sus folds a pesar del dropout, el weight decay, el early stopping y los pesos de clase. El resultado más caro confirmó el patrón: el fine-tuning end-to-end de WavLM-large con aumentación llegó a 0,788 en promedio (4 folds), lejos del enfoque de features congeladas y con un costo computacional dos órdenes de magnitud mayor. Con pocos datos, tocar los 317M de parámetros es peor que dejarlos quietos.

IV-E. Optimización del sistema final

La Tabla III resume el camino desde el mejor modelo individual hasta el ensemble. Pasar a WavLM-large aporta +3,7 puntos sobre wav2vec2-base y combinar representaciones suma +0,9. La aumentación de pseudo-hablantes beneficia sobre todo al MLP (0,847 $\rightarrow$ 0,876), consistente con que las redes son las que más sufren la escasez de hablantes. El ensemble de tres backbones llega a 0,882, y con el MLP aumentado más la ponderación final alcanza **0,890** / 0,888 de macro-F1. La Figura 2 resume el recorrido completo desde el baseline. La Figura 3 muestra la matriz de confusión del sistema final: los errores que quedan se concentran en pares de activación parecida, tristeza–calma (baja activación) y felicidad–sorpresa (alta).

IV-F. Discusión: diversidad sobre fuerza individual

Un experimento posterior ilustra por qué funciona el ensemble, y es el hallazgo que más nos gustó del trabajo. El MLP usa

Tabla III
OPTIMIZACIÓN AVANZADA Y ENSEMBLE (SPEECH, GROUPKFOLD-5).

Sistema	Accuracy	Macro-F1
WavLM-large top-3 + CMVN (LogReg)	0,864	0,863
WavLM + base + eGeMAPS + CMVN	0,873	0,871
MLP (WavLM+base) + aumentación	0,876	—
Ensemble 3 backbones	0,882	0,880
Ensemble + MLP aum.	0,888	0,886
Ensemble final ponderado (2-2-1-1)	0,890	0,888
Fine-tuning WavLM-large + aum.	0,788	0,782




Figura 3. Matriz de confusión (recall por clase) del ensemble final sobre RAVDESS speech, predicciones out-of-fold.

como entrada WavLM+base. Al enriquecerlo con HuBERT su rendimiento individual mejoró (0,874 $\rightarrow$ 0,883, su mejor valor aislado), pero el ensemble *empeoró* (0,890 $\rightarrow$ 0,887). ¿Por qué? El MLP se volvió más parecido a los votantes lineales, que ya usan HuBERT, y al promediar aportó menos información nueva. En un ensemble importan más los errores no correlacionados que la fuerza de cada miembro: el votante más débil pero distinto complementa mejor que el más fuerte pero redundante.

Sobre el sobreajuste: la validación speaker-disjoint elimina la vía principal (memorizar voces), y la regularización fuerte, el early stopping y la aumentación controlan la capacidad. Igual somos conscientes de un riesgo más fino: hicimos decenas de comparaciones contra el mismo protocolo de validación cruzada, y elegir el mejor sistema con esas mismas métricas puede sobreajustar la selección. Por eso importa la evaluación cross-corpus que sigue: es el único número del trabajo que el proceso de desarrollo no pudo contaminar.

IV-G. Generalización cross-corpus: EMODB

La Tabla IV muestra qué pasa al aplicar el sistema final, sin reentrenar, a un corpus en alemán. Sin ninguna adaptación

Tabla IV
CAMBIO DE DOMINIO: RAVDESS $\rightarrow$ EMODB (454 AUDIOS, 6 CLASES).

Variante	Accuracy	Macro-F1
Sin CMVN	0,570	0,578
Con CMVN por hablante	0,767	0,787




Figura 4. Matriz de confusión (recall por clase) sobre EMODB con CMVN. El error dominante es enojo $\rightarrow$ felicidad, pares de alta activación.

el accuracy cae de 0,890 a 0,570. Es una caída grande, pero queda muy por encima del azar ($1/6 \approx 0,167$), señal de que los embeddings SSL capturan algo de la emoción paralingüística que no es exclusivo del inglés. Aplicar CMVN con las estadísticas de los hablantes de EMODB recupera casi 20 puntos (0,767): la mitad del camino de vuelta al rendimiento in-domain, con la intervención más barata disponible. La Figura 4 muestra que el error dominante que queda es enojo clasificado como felicidad (36 de 127 casos). Tiene sentido acústico: las dos comparten activación alta (energía y F0 elevados) y se distinguen por la valencia, que es la dimensión más difícil de SER.

V. CONCLUSIÓN Y TRABAJO FUTURO

Construimos un sistema de SER que mejora de 0,465 a 0,890 de accuracy speaker-disjoint sobre RAVDESS. Las lecciones principales no son las que esperábamos al arrancar. Primero, la ganancia dominante no vino de modelos más grandes sino de controlar el confound de hablante (CMVN, +7 puntos). Segundo, con ~ 1400 ejemplos los modelos lineales regularizados le ganan a MLP, CRNN y fine-tuning end-to-end, y las redes solo aportan como votante diverso de un ensemble. Tercero, en el ensemble la diversidad de errores vale más que el rendimiento individual de cada miembro. La evaluación cross-corpus sobre EMODB (0,767 sin reentrenar) sugiere que el sistema captura emoción genuina y que normalizar por hablante es también la herramienta clave frente al cambio de dominio.

Con más tiempo exploraríamos fine-tuning con corpus multilingües más grandes (donde el enfoque end-to-end debería revertir su desventaja), calibración y adaptación ligera al dominio destino (con unos pocos audios por hablante alcanza para estimar CMVN, como mostró EMOVB) y la dimensión de valencia, que concentra los errores restantes. Como paso hacia la aplicación real, armamos además una demo web local que graba audio del micrófono y predice la emoción por fragmentos casi en tiempo real, incluida en el código fuente.

REFERENCIAS

- [1] S. R. Livingstone y F. A. Russo, “The Ryerson Audio-Visual Database of Emotional Speech and Song (RAVDESS),” *PLoS ONE*, vol. 13, no. 5, e0196391, 2018.
- [2] F. Eyben *et al.*, “The Geneva Minimalistic Acoustic Parameter Set (GeMAPS) for voice research and affective computing,” *IEEE Trans. Affective Computing*, vol. 7, no. 2, pp. 190–202, 2016.
- [3] F. Eyben, M. Wöllmer y B. Schuller, “openSMILE: the Munich versatile and fast open-source audio feature extractor,” en *Proc. ACM Multimedia*, 2010, pp. 1459–1462.
- [4] A. Baevski, H. Zhou, A. Mohamed y M. Auli, “wav2vec 2.0: A framework for self-supervised learning of speech representations,” en *Proc. NeurIPS*, 2020.
- [5] S. Chen *et al.*, “WavLM: Large-scale self-supervised pre-training for full stack speech processing,” *IEEE J. Sel. Topics Signal Process.*, vol. 16, no. 6, pp. 1505–1518, 2022.
- [6] W.-N. Hsu *et al.*, “HuBERT: Self-supervised speech representation learning by masked prediction of hidden units,” *IEEE/ACM Trans. Audio, Speech, Lang. Process.*, vol. 29, pp. 3451–3460, 2021.
- [7] L. Pepino, P. Riera y L. Ferrer, “Emotion recognition from speech using wav2vec 2.0 embeddings,” en *Proc. Interspeech*, 2021, pp. 3400–3404.
- [8] C. Doğdu, T. Kessler, D. Schneider, M. Shadaydeh y S. R. Schweinberger, “A comparison of machine learning algorithms and feature sets for automatic vocal emotion recognition in speech,” *Sensors*, vol. 22, no. 19, 7561, 2022.
- [9] F. Burkhardt, A. Paeschke, M. Rolfes, W. Sendlmeier y B. Weiss, “A database of German emotional speech,” en *Proc. Interspeech*, 2005, pp. 1517–1520.
- [10] F. Pedregosa *et al.*, “Scikit-learn: Machine learning in Python,” *J. Mach. Learn. Res.*, vol. 12, pp. 2825–2830, 2011. Se utilizaron además PyTorch y HuggingFace Transformers.